UNIVERSIDAD CATÓLICA DE SANTIAGO DEL ESTERO
FACULTAD DE CIENCIAS DE LA SALUD / INFORMÁTICA

VOZREAL: MARCO TEÓRICO, ANTECEDENTES, ESTADO DEL ARTE Y DEFINICIÓN DE PRODUCTO

Fundamentación científica, análisis de mercado, arquitectura tecnológica y modelo de entrega para la mitigación del vishing y la suplantación de identidad por IA en dispositivos móviles

Campo	Detalle
Proyecto	VozReal (TP2)
Cátedra	Emprendedorismo
Etapa	Pre-Semilla / Estado del Arte y Definición de Producto
Fecha	Agosto a Septiembre de 2026
Áreas disciplinares	Procesamiento de señales, ciberseguridad, Edge AI, gerontotecnología, diseño de producto.
Destinatarios	Cuerpo docente evaluador. Marco de validación técnica, teórica y de modelo de negocio.

RESUMEN EJECUTIVO Y DECLARACIÓN DE PROPÓSITO

El presente documento constituye el cuerpo formal de fundamentación teórica, relevamiento del estado del arte y definición de producto para el proyecto VozReal. Su objetivo es dotar a la propuesta de rigor conceptual, científico y tecnológico, respondiendo a la necesidad crítica de proteger a usuarios vulnerables (específicamente adultos mayores y sus núcleos familiares) contra la creciente ola de estafas telefónicas (vishing), secuestros virtuales y suplantación de identidad mediante clonación de voz (voice cloning y deepfakes de audio).

Se articulan cinco ejes fundamentales: (1) la problematización criminológica y biopsicosocial; (2) el marco teórico del procesamiento de señales acústicas, biometría de voz y redes neuronales on-device; (3) los antecedentes académicos y competencias del estado del arte internacional (ASVspoof); (4) un riguroso benchmarking de soluciones de mercado existentes, explicitando las razones estructurales por las cuales fallan ante las nuevas modalidades delictivas; y (5) la definición funcional del producto, la decisión de arquitectura de entrega (aplicación móvil, servicio sobre la línea telefónica o modelo híbrido) y el diseño del sistema de alertas.

En cuanto a la decisión de producto, este documento resuelve de manera explícita y fundamentada que VozReal se materializa como una aplicación móvil Android con inferencia local (Edge AI) concebida desde el diseño para integrarse, en una segunda fase, como servicio de valor agregado de las operadoras de telefonía móvil. Se trata, por lo tanto, de un modelo híbrido secuencial: el producto núcleo es la aplicación, y la asociación con la línea telefónica opera como canal de distribución, mecanismo de cobro y capa adicional de señales de red, sin que el sistema dependa de dicha asociación para funcionar.

DESCRIPTORES BIBLIOGRÁFICOS DEL DOCUMENTO

Descriptores: vishing; deepfake de audio; clonación de voz; verificación automática de locutor (ASV); anti-spoofing de audio; biometría vocal; Edge AI; inferencia on-device; ECAPA-TDNN; AASIST; ingeniería social; secuestro virtual; suplantación de identidad; Caller ID spoofing; gerontotecnología; adultos mayores; privacidad por diseño; Ley 25.326; Android; verificación intrafamiliar.

Descriptors: *vishing; audio deepfake; voice cloning; automatic speaker verification (ASV); audio anti-spoofing; voice biometrics; edge AI; on-device inference; ECAPA-TDNN; AASIST; social engineering; virtual kidnapping; identity spoofing; caller ID spoofing; gerontechnology; older adults; privacy by design; Android; intra-family verification.*

EJES TEMÁTICOS PARA INDEXACIÓN

Eje técnico principal: procesamiento digital de señales de voz y aprendizaje profundo aplicado a la detección de habla sintética.

Eje social principal: protección de poblaciones vulnerables frente al fraude telefónico asistido por inteligencia artificial generativa.

Eje de negocio principal: producto de consumo masivo de bajo costo distribuido mediante canal directo y alianza con operadoras de telecomunicaciones (modelo B2C y B2B2C).

Eje de producto principal: autenticación familiar de triple factor, combinando biometría de voz, reputación del número y una palabra clave de seguridad compartida.

Nota aclaratoria: estos descriptores son términos de indexación académica del presente documento y no deben confundirse con la funcionalidad de Palabras Clave de Seguridad del producto, definida y especificada en el apartado 5.7.

1. PROBLEMATIZACIÓN SOCIOTÉCNICA Y CONTEXTUALIZACIÓN

1.1. La metamorfosis del delito telefónico: de la estafa tradicional al deepfake de audio

El fraude telefónico, tradicionalmente conocido en Argentina y la región rioplatense como el "cuento del tío", ha dejado de ser una simple maniobra de persuasión verbal o teatro psicológico elemental para convertirse en una operación de ciberdelincuencia de alta precisión tecnológica. Históricamente, los secuestros virtuales dependían de la sorpresa, ruidos de fondo confusos y gritos desesperados fingidos que impedían a la víctima distinguir con claridad la identidad acústica del emisor. En este esquema analógico, el éxito del estafador dependía casi exclusivamente de la velocidad de ejecución y de impedir que la víctima cortara la comunicación para corroborar la información.

Sin embargo, la irrupción masiva de la Inteligencia Artificial Generativa (IAGen) ha quebrado el axioma perceptivo elemental de la comunicación humana: "reconozco la voz, por lo tanto es mi familiar". Mediante el advenimiento de modelos de clonación de voz con capacidades de transferencia Zero-Shot (tales como VITS, XTTS-v2, Bark o servicios comerciales de API abierta como ElevenLabs), un actor malicioso solo requiere un fragmento de audio limpio de 3 a 10 segundos extraído de un estado público de WhatsApp, un video en redes sociales (TikTok, Instagram) o un mensaje de voz filtrado para sintetizar el timbre exacto, la cadencia, el tono y los formantes vocales de un hijo o nieto.

1.2. El fenómeno del vishing (voice phishing) y la ingeniería social asistida por IA

El vishing (acrónimo de voice phishing) representa la vectorización de la ingeniería social a través del canal de voz interactivo. A diferencia del phishing por correo electrónico o SMS (smishing), donde la víctima puede

inspeccionar visualmente un enlace o tomarse minutos para evaluar la veracidad del mensaje, el canal telefónico sincrónico impone una carga de respuesta en tiempo real.

La integración de bots conversacionales impulsados por Modelos Masivos de Lenguaje (LLMs) con sintetizadores de habla de ultra baja latencia permite hoy en día la automatización de llamadas de prospección masiva. Los sistemas realizan miles de llamados simultáneos con numeraciones rotativas; cuando una persona atiende, un bot de voz interactivo califica la susceptibilidad de la víctima en los primeros 5 segundos antes de derivar la llamada a un operador humano especializado o activar un guion extorsivo automatizado.

1.3. Vulnerabilidad geriátrica y la dimensión biopsicosocial del fraude

Los adultos mayores constituyen el blanco primario y desproporcionadamente afectado por esta tipología delictiva. Desde la perspectiva de la gerontología y la neuropsicología cognitiva, esta vulnerabilidad no responde a una falta de inteligencia o instrucción, sino a factores neurobiológicos y sociales bien documentados en la literatura científica (Spreng et al., 2016; Castle et al., 2012):

- **Efecto de "secuestro de la amígdala" (amygdala hijack):** ante la percepción de una amenaza inminente hacia un ser querido (un accidente grave, un secuestro, una detención policial violenta), el sistema límbico bloquea las funciones ejecutivas del córtex prefrontal dorsolateral. La capacidad de razonamiento lógico, verificación de incongruencias temporales y juicio crítico queda anulada por una respuesta de pánico biológico.
- **Confianza social preservada e ingenuidad perceptiva:** investigaciones en neurobiología del envejecimiento demuestran que los adultos mayores experimentan una atenuación en la activación de la ínsula anterior ante señales faciales o vocales de desconfianza o engaño, lo que se traduce en una mayor propensión basal a conceder veracidad a quien habla.
- **Aislamiento y asimetría de información tecnológica:** la velocidad exponencial con la que han evolucionado las herramientas de síntesis de voz no ha sido acompañada por una alfabetización digital equivalente. Para un adulto mayor, la idea de que una voz humana pueda ser falsificada en tiempo real con una computadora resulta contraintuitiva y prácticamente inverosímil.

1.4. El escenario criminológico y regulatorio en Argentina y Santiago del Estero

El contexto socioespacial de Santiago del Estero y las provincias del Noroeste Argentino (NOA) presenta características críticas que agravan la situación. De acuerdo con los relevamientos anuales de la Unidad Fiscal Especializada en Ciberdelincuencia (UFECI), las estafas virtuales y telefónicas han liderado el crecimiento de denuncias penales en el fuero federal y provincial, registrando incrementos anuales sostenidos superiores al 200% desde 2020.

> **FACTORES ESTRUCTURALES LOCALES DE VULNERABILIDAD**
>
> Mercado informal de telefonía prepaga: existencia de circuitos de venta de tarjetas SIM activadas sin validación biométrica fehaciente en quioscos y comercios no oficiales, lo que permite a organizaciones delictivas descartar decenas de líneas por día.
>
> Ausencia de validación de cabecera SIP (Caller ID spoofing): la red telefónica conmutada argentina y los enlaces VoIP de las operadoras locales no tienen implementado de manera obligatoria el protocolo STIR/SHAKEN, permitiendo que un atacante inyecte cualquier número de remitente en la pantalla de la víctima (incluso el número real de un banco o de una comisaría local).
>
> Impacto económico devastador: en economías de ingresos medios y jubilaciones mínimas, el vaciamiento de una cuenta sueldo mediante transferencias forzadas o la entrega de ahorros físicos bajo amenaza destruye de forma irreversible el patrimonio de una vida familiar.

2. MARCO TEÓRICO MULTIDISCIPLINAR

2.1. Procesamiento de señales de audio y biometría vocal (Speaker Verification, ASV)

La verificación automática de locutor (Automatic Speaker Verification, ASV) consiste en responder mediante métodos computacionales a la pregunta: ¿es esta muestra de audio emitida por la persona que afirma ser? A nivel físico y acústico, la voz humana es el resultado de la excitación generada por el flujo de aire laríngeo a través de las cuerdas vocales, modulado por las cavidades de resonancia del tracto vocal (faringe, cavidad oral y nasal).

2.1.1. Extracción de características espectro-temporales

El habla es una señal no estacionaria pero cuasi-estacionaria en ventanas temporales cortas (20 a 30 milisegundos). Para digitalizar y parametrizar la singularidad de un hablante, se recurre a representaciones en el dominio de la frecuencia:

- **Coeficientes cepstrales en las frecuencias de Mel (MFCC):** mapean el espectro de potencia de una señal a través de un banco de filtros espaciados según la escala perceptual Mel, simulando la respuesta no lineal del oído humano a diferentes frecuencias. Han sido el estándar tradicional para capturar las características del tracto vocal.
- **Coeficientes cepstrales en escala lineal (LFCC):** a diferencia de los MFCC, los filtros LFCC mantienen un espaciado lineal en todo el espectro de frecuencias. Si bien son menos representativos de la percepción psicoacústica humana, la literatura científica ha demostrado que son superiores para capturar artefactos de alta frecuencia producidos por algoritmos de síntesis vocal.
- **Transformada Q constante (CQT / CQCC):** ofrece una resolución temporal superior en altas frecuencias y una resolución frecuencial más fina en bajas frecuencias, permitiendo aislar discontinuidades armónicas sutiles.

2.1.2. De los i-vectors a las redes neuronales profundas (ECAPA-TDNN)

La evolución de los modelos de biometría vocal ha transitado por tres generaciones paradigmáticas:

1. **Modelos estadísticos clásicos (GMM-UBM e i-vectors):** basados en la concatenación de medias de Modelos de Mezclas Gaussianas adaptados desde un Modelo Universal de Fondo (UBM), proyectados en un espacio de baja dimensión denominado espacio de variabilidad total. Sensibles al ruido y a variaciones de canal telefónico.
2. **x-vectors (Snyder et al., 2018):** arquitecturas basadas en Redes Neuronales con Retardo Temporal (TDNN) que procesan contextos temporales extensos y extraen un vector de características latentes (embedding) a través de una capa de agrupamiento estadístico (statistical pooling).
3. **ECAPA-TDNN (Desplanques et al., 2020):** representa el estado del arte absoluto en biometría vocal. Incorpora tres innovaciones estructurales críticas: canales de atención residuales (Squeeze-and-Excitation), que ponderan dinámicamente qué canales de frecuencia son más relevantes para la identidad del hablante; propagación multicapa, que reutiliza características de capas previas combinando información fonética de bajo nivel con información acústica abstracta de alto nivel; y agrupamiento de atención temporal ponderada, que asigna mayor peso a los fotogramas del habla que contienen fonemas ricos en formantes y descarta segmentos con ruido o silencio.

SIMILITUD DE VECTORES DE IDENTIDAD VOCAL

cos(theta) = (e_test . e_ref) / (||e_test|| . ||e_ref||)

Score_PLDA = log [P(e_test, e_ref | misma persona) / P(e_test, e_ref | distintas personas)]

2.2. Audio anti-spoofing y detección de síntesis vocal (deepfake detection)

El desafío central de VozReal radica en distinguir una voz natural transmitida a través de la red telefónica de una voz sintética generada por algoritmos de Text-to-Speech (TTS) o Voice Conversion (VC).

2.2.1. Taxonomía de ataques de suplantación de voz

Tipo de ataque	Mecanismo técnico	Manifestación en el contexto delictivo
Text-to-Speech (TTS) sintético	Modelos acústicos neuronales (Tacotron 2, FastSpeech 2, VITS) acoplados a vocoders neuronales (HiFi-GAN, WaveGlow, Diffusion) que convierten texto plano en voz hablada con la identidad acústica del objetivo.	El estafador escribe en tiempo real en una consola web frases de socorro y la herramienta reproduce el audio clonado directamente en la llamada.
Voice Conversion (VC) en vivo	Mapeo espectral de secuencia a secuencia (StarGAN-v2-VC, FreeVC, RVC) que transforma las características del habla de un operador humano al timbre del familiar suplantado conservando la entonación y emoción original.	El extorsionador habla por un micrófono con un modulador neuronal en tiempo real; sus palabras se emiten instantáneamente con la voz del hijo o nieto de la víctima.
Replay attacks (repetición)	Reproducción de una grabación real auténtica previamente obtenida (por ejemplo, un audio de WhatsApp) a través de un altavoz externo apuntado al teléfono.	Uso de audios fragmentarios ("Hola ma, ¿cómo andás?", "Ayudame por favor") para desorientar en los primeros segundos de la comunicación.

2.2.2. Biomarcadores físicos y artefactos de detección

Aunque los modelos generativos contemporáneos logran un índice de calidad percibida (MOS, Mean Opinion Score) indistinguible para el oído humano, introducen anomalías matemáticas y físicas medibles:

- **Inconsistencia y distorsión de fase:** la mayoría de los vocoders sintetizan magnitudes espectrales y reconstruyen la fase de manera artificial (algoritmo de Griffin-Lim o redes de discriminación convolucional). Esto genera discontinuidades sutiles en la envolvente temporal instantánea y cancelaciones de fase inexistentes en el tracto vocal humano.
- **Pérdida y colapso de armónicos en altas frecuencias:** los modelos de difusión y redes generativas antagónicas (GANs) presentan dificultades para modelar la textura espectral estocástica por encima de los 3.5 kHz, exhibiendo bandas de silencio artificial o patrones de repetición fija (spectral ringing).
- **Ausencia de biomarcadores respiratorios e involuntarios:** el habla humana está físicamente acoplada a la capacidad pulmonar y al sistema respiratorio. La emisión prolongada sin micro-pausas inspiratorias, la ausencia de transiciones de aire nasal, o la falta de clics de salivación e impacto glótico previo al ataque consonántico revelan una generación puramente algorítmica.

2.2.3. Modelos de referencia: de RawNet2 a AASIST

En la investigación de vanguardia, el procesamiento no se limita a espectrogramas estáticos. Modelos como RawNet2 operan directamente sobre la onda de audio en crudo (raw waveform) utilizando filtros SincNet en su primera capa, lo que permite al modelo aprender representaciones adaptativas de baja y alta frecuencia sin las pérdidas introducidas por la Transformada de Fourier. Por su parte, la arquitectura AASIST (Tak et al., 2021) emplea Redes de Atención en Grafos (GAT) integradas espectro-temporales, analizando la correlación cruzada entre diferentes bandas de frecuencia y segmentos temporales para detectar artefactos dispersos.

2.3. Arquitectura on-device (Edge AI) y privacidad por diseño

El pilar fundacional de VozReal exige que ningún flujo de audio ni dato biométrico abandone el terminal del usuario. Esto no solo responde a una estricta política de soberanía y ética digital, sino a condicionantes operativos insoslayables:

- **Latencia crítica de decisión:** la alerta debe dispararse dentro de los primeros 2 a 3 segundos de conversación. En redes celulares móviles de regiones del interior (3G, 4G con fluctuaciones de señal), el retardo de compresión, subida a un servidor en la nube, procesamiento y retorno de respuesta excedería con creces los 4 a 6 segundos, tiempo durante el cual la víctima ya ha caído bajo el influjo del atacante.
- **Resiliencia sin conectividad:** las llamadas de telefonía fija o celular convencional (PSTN / GSM) pueden ingresar en zonas con nula o deficiente conectividad de datos móviles. El sistema de protección debe ser completamente autónomo.
- **Seguridad de plantillas biométricas:** un servidor centralizado que almacene millones de huellas de voz de ciudadanos latinoamericanos se convertiría en un blanco de ataque catastrófico (honey pot). Al procesar localmente, la superficie de ataque se atomiza por completo.

Técnicas de optimización on-device	Entornos de ejecución embebida
Cuantización post-entrenamiento (INT8): reducción de la precisión de pesos de punto flotante FP32 a enteros de 8 bits. Reduce el tamaño del modelo en un 75% y acelera la inferencia en DSP/NPU móvil con una degradación del EER menor al 0.8%.	ONNX Runtime Mobile y TFLite: motores de inferencia optimizados para procesadores ARM Cortex-A con soporte para instrucciones SIMD NEON y aceleración vía Android NNAPI.
Destilación de conocimiento (knowledge distillation): transferencia de capacidad de discriminación desde un modelo maestro pesado (WavLM Large, 315M parámetros) a un modelo alumno compacto (MobileNetV4 modificado o Tiny-ECAPA, menos de 5M parámetros).	Presupuesto de cómputo móvil: ejecución acotada a una ventana de 2.0 segundos de audio, demandando menos de 80 MB de memoria RAM y un consumo energético que no supera el 0.05% de la batería por llamada analizada.

2.4. Gerontotecnología e interacción humano-computadora (HCI) bajo estrés

El diseño de interfaces para situaciones de crisis requiere aplicar principios de diseño centrado en el humano adaptados a la psicología del adulto mayor:

- **Mitigación de la fatiga de alerta:** si una aplicación emite alertas constantes ante llamadas legítimas (falsos positivos), el usuario termina por silenciar, desinstalar o ignorar el sistema. Por ello, VozReal adopta un esquema de semáforo cognitivo discreto pero contundente, detallado en el apartado 5.8.
- **Lenguaje explicable y no determinista:** el sistema nunca afirma categorías absolutas como "llamada 100% segura" o "llamada 100% falsa", dado que la biometría es intrínsecamente probabilística. Se emplean frases directas, de lectura instantánea y tipografía de alto contraste (WCAG 2.2 nivel AAA): "Atención: esta voz no suena como tu hija".
- **El segundo factor humano (protocolo de desafío intrafamiliar):** cuando el sistema detecta indicios de suplantación, no corta la llamada (lo que podría inducir un pánico incontrolable si la persona cree que su familiar sigue en peligro), sino que despliega en la pantalla una pregunta de verificación familiar configurada previamente (por ejemplo: "Preguntale cómo se llamaba el perro que teníamos en el campo"). Esta sencilla acción traslada la dinámica de la conversación desde el plano emocional y reactivo al plano analítico, neutralizando de inmediato al delincuente o al bot. Este mecanismo se formaliza y amplía en el apartado 5.7 bajo la figura de las palabras clave de seguridad.

3. ANTECEDENTES ACADÉMICOS Y DE INVESTIGACIÓN (ESTADO DEL ARTE)

3.1. La iniciativa internacional ASVspoof Challenge (2015 a 2024 / ASVspoof 5)

El referente científico obligado a nivel global en la lucha contra la manipulación de voz es la iniciativa ASVspoof, impulsada por un consorcio internacional de universidades y laboratorios (incluyendo Inria,

Universidad de Edimburgo, EURECOM y la Asociación Internacional de Comunicación del Habla, ISCA). A lo largo de sus ediciones bienales, ASVspoof ha evolucionado desde la detección de ataques de repetición y síntesis básica (2015, 2017) hacia escenarios altamente complejos:

- **ASVspoof 2019:** estableció dos pistas de evaluación estándar: Logical Access (LA), con TTS y VC neuronales avanzados, y Physical Access (PA), con repetición en salas acústicas con múltiples reverberaciones. Introdujo la métrica unificada t-DCF (tandem Detection Cost Function), que evalúa el costo del error en un sistema compuesto donde el módulo anti-spoofing opera en tándem con un sistema de verificación de locutor.
- **ASVspoof 2021:** introdujo la pista de evaluación sobre canales de transmisión telefónica y VoIP sin comprimir y comprimidos (códecs G.711 A-law y mu-law, AMR, Opus), demostrando que la compresión con pérdidas degrada sustancialmente el rendimiento de los detectores si no son entrenados con datos aumentados acústicamente.
- **ASVspoof 5 (2024):** focalizado en la detección de deepfakes de voz generados por modelos contemporáneos de difusión latente y modelos fundacionales de habla (como SeamlessM4T, Voicebox y VALL-E), evaluando la capacidad de generalización frente a ataques con vocoders nunca antes vistos por el clasificador (unseen attacks).

3.2. Proyectos científicos y benchmarks abiertos de detección de fraude

En el ámbito de la investigación aplicada se destacan tres proyectos fundamentales:

- **DARPA SemaFor (Semantic Forensics):** programa gubernamental de defensa de los Estados Unidos enfocado en la detección de manipulaciones mediáticas multimodales. En el dominio de audio, SemaFor financió desarrollos pioneros en el análisis de inconsistencias semántico-acústicas (por ejemplo, discordancias entre la supuesta edad o género del hablante y las resonancias del tracto vocal medidas físicamente).
- **In-the-Wild Audio Deepfake Dataset (Müller et al., 2022):** primer conjunto de datos abierto de voces sintéticas reales recolectadas de entornos no controlados de Internet (YouTube, podcasts, redes sociales), demostrando que los modelos entrenados exclusivamente en laboratorio sufren un incremento drástico en la tasa de error (el EER sube del 2% al 18%) al enfrentarse a canales de audio reales con compresión, ruido de fondo y cortes de paquete.
- **Estudios de vulnerabilidad financiera de Stanford Center on Longevity:** investigaciones dirigidas por la Dra. Laura Carstensen que demuestran experimentalmente que la inducción de estados de alta excitación emocional (miedo o excitación positiva extrema) incrementa en un 400% la probabilidad de que un adulto mayor tome decisiones de transferencia económica inmediatas ante solicitudes fraudulentas.

4. BENCHMARKING DE MERCADO Y ANÁLISIS DE SOLUCIONES SIMILARES

4.1. Matriz comparativa multidimensional de soluciones

Para dimensionar con exactitud el posicionamiento de VozReal, se presenta a continuación un análisis comparativo frente a las aplicaciones comerciales más extendidas a nivel global y las herramientas de última generación:

Plataforma	Mecanismo central de detección	¿Detecta voz sintética?	¿Verifica familiares?	Procesamiento local	Efectividad ante Caller ID spoofing
Truecaller (líder global anti-spam)	Listas negras colaborativas (crowdsourcing) y cruce con bases de números denunciados.	NO. Solo evalúa el número telefónico.	NO. Sin noción de biometría familiar.	NO. Consulta a servidores en nube.	NULA. Si clonan el número de un familiar, lo muestra como seguro.

Plataforma	Mecanismo central de detección	¿Detecta voz sintética?	¿Verifica familiares?	Procesamiento local	Efectividad ante Caller ID spoofing
Hiya / Samsung Smart Call (integración OEM)	Análisis de metadatos de señalización de operadoras y patrones de llamadas masivas.	NO. No analiza el contenido de audio.	NO. Solo categoriza empresas y spam.	PARCIAL. Caché local con consulta a nube.	MUY BAJA. Vulnerable a números nuevos o suplantados en cabecera SIP.
RoboKiller (consumer anti-spam)	Fingerprinting acústico de mensajes pregrabados masivos y respuesta con answer bots.	LIMITADO. Solo mensajes masivos repetidos idénticos.	NO. Diseñado para marketing masivo.	NO. Requiere desvío de llamada a nube.	BAJA. No protege contra ataques dirigidos a una persona concreta.
Google Pixel Scam Detection (2024-2025)	Transcripción en tiempo real y análisis semántico conversacional con Gemini Nano.	INDIRECTO. Detecta el guion o la intención, no la acústica.	NO. No compara biometría acústica familiar.	SÍ. On-device vía NPU Tensor en móviles Pixel.	MODERADA. Alerta si el atacante pide giros de dinero bancarios.
BioCatch / Nuance Gatekeeper (seguridad bancaria)	Biometría conductual y verificación de voz en centrales telefónicas bancarias.	SÍ. Modelos anti-spoofing corporativos.	NO. Verifica cliente ante el banco, no familiar ante usuario.	NO. Arquitectura de servidor corporativo.	No aplica. Solo cubre clientes llamando a la mesa de ayuda del banco.
VozReal (nuestra propuesta)	Triple capa jerárquica: reputación de número, detección de bot y síntesis, y biometría intrafamiliar.	SÍ. Análisis espectral y detección de artefactos TTS/VC.	SÍ. Comparación con huella local registrada voluntariamente.	SÍ (100%). Inferencia local, privacidad absoluta, sin nube.	TOTAL. Si suplantan el número pero la voz no coincide, dispara la alerta roja.

4.2. Análisis crítico pormenorizado de las soluciones existentes

4.2.1. Truecaller y Hiya: la falacia de la reputación telefónica

Truecaller cuenta con más de 350 millones de usuarios activos y una base masiva de spam telefónico. Sin embargo, su modelo arquitectónico sufre de tres deficiencias fatales frente al vishing de nueva generación:

1. **Incapacidad absoluta frente al Caller ID spoofing:** como Truecaller toma la cadena de texto y dígitos enviada en la señalización SS7/SIP para consultar su base de datos, si un delincuente falsifica el Caller ID para que figure el número exacto del hijo o pareja de la víctima, Truecaller mostrará el nombre legítimo y la foto de perfil asociada, otorgando un peligroso sello de autenticidad al atacante.
2. **La ventana de impunidad de las líneas nuevas:** una tarjeta SIM prepaga adquirida minutos antes para cometer un secuestro virtual no posee historial ni denuncias en la base colaborativa. Para Truecaller es un número neutral no categorizado.
3. **Riesgo severo de privacidad y legalidad:** para funcionar de manera comunitaria, estas herramientas exigen que el usuario entregue su agenda telefónica completa a servidores radicados en el extranjero, práctica sumamente cuestionada bajo legislaciones modernas de protección de datos (RGPD de la Unión Europea y Ley 25.326 de Argentina).

4.2.2. RoboKiller y los answer bots

RoboKiller ha tenido éxito comercial en los Estados Unidos combatiendo llamadas automatizadas masivas de seguros o telemarketing mediante el desvío condicional de llamadas a servidores donde bots humorísticos contestan al operador de spam. Esta solución es enteramente inaplicable al secuestro virtual y a la extorsión familiar:

- Requiere configurar el desvío de llamadas del operador hacia la infraestructura de RoboKiller, introduciendo costos adicionales, demoras en la conexión y perdiendo el control directo sobre la línea.

- No cuenta con la capacidad ni con el propósito de evaluar la identidad acústica de un interlocutor en una conversación interactiva privada.

4.2.3. Google Pixel Call Screen y Scam Detection (avances 2024-2025)

A finales de 2024, Google presentó en sus dispositivos Pixel de última serie una funcionalidad nativa de detección de estafas impulsada por su modelo de lenguaje miniaturizado Gemini Nano. Este hito valida industrialmente la hipótesis de VozReal: la necesidad imperiosa de ejecutar IA en el propio teléfono para proteger al usuario durante la llamada. No obstante, el enfoque de Google presenta barreras infranqueables para la realidad latinoamericana y el caso de uso familiar:

- **Exclusividad de hardware premium:** Gemini Nano y la NPU requerida están restringidos a smartphones de la línea Google Pixel 8 Pro y 9, dispositivos con una penetración de mercado prácticamente nula (menos del 0.5%) en Argentina y América Latina, donde el parque de smartphones de adultos mayores está dominado por gamas bajas y medias de marcas como Samsung, Motorola y Xiaomi.
- **Detección semántica frente a detección acústica:** Google transcribe el audio a texto y busca patrones de fraude transaccional (tarjetas de regalo, transferencia urgente a cuenta bancaria, claves de home banking). Este enfoque falla ante secuestros virtuales y extorsiones donde el diálogo inicial no contiene palabras financieras estándar, sino gritos, llanto o pedidos de rescate informal en efectivo.
- **Carencia de biometría intrafamiliar:** Google no ofrece un mecanismo para que un usuario registre la huella vocal de sus familiares cercanos para validar si quien llama con la voz de su hijo es efectivamente su hijo.

4.3. La brecha de mercado (white space) y la propuesta de valor de VozReal

El análisis del estado del arte evidencia una brecha tecnológica desatendida a nivel mundial: no existe en el mercado de consumo masivo una solución móvil accesible que analice la autenticidad física de la voz y verifique la identidad del núcleo íntimo de forma local.

> **EL PARADIGMA DIFERENCIAL DE VOZREAL**
>
> VozReal llena este vacío articulando una estrategia de tres capas complementarias: combina el filtrado heurístico de reputación numérica tradicional (Capa 1) con la detección física de artefactos de síntesis algorítmica (Capa 2, anti-spoofing) y el cotejo biométrico 1:1 contra plantillas cifradas de contactos familiares clave (Capa 3, verificación local). Todo ello ejecutado en procesadores móviles estándar de costo accesible y traducido a una alerta gerontológica comprensible en milisegundos.
>
> A estas tres capas se suma, en la fase de asociación con operadoras descrita en el apartado 5.5, una Capa 0 de señales de red que ninguna aplicación de terceros puede obtener por sí sola.
>
> Y por encima de todas ellas opera un factor de conocimiento compartido, la palabra clave de seguridad acordada dentro de la familia, que resuelve el único escenario que ningún modelo acústico puede garantizar por sí solo: una clonación de altísima fidelidad emitida desde un número suplantado.

5. DEFINICIÓN DEL PRODUCTO, MODELO DE ENTREGA Y SISTEMA DE ALERTAS

Este capítulo traduce el marco teórico precedente en una definición operativa y comercial del producto. Responde de manera taxativa a cuatro preguntas que el cuerpo evaluador exige resolver en la instancia de pre-semilla: qué hace exactamente VozReal, a quién protege dentro de la familia, si se materializa como aplicación, como servicio prestado sobre la línea telefónica o como una articulación de ambos, y cómo se comporta el sistema en el instante concreto en que detecta spam, fraude o suplantación.

5.1. Definición funcional del producto

DEFINICIÓN CANÓNICA

VozReal es un sistema de verificación de identidad vocal y detección de habla sintética que opera en tiempo real durante las llamadas entrantes, se ejecuta íntegramente dentro del teléfono de la persona protegida y responde, en menos de tres segundos, a dos preguntas: (a) ¿quien está hablando es una persona real o una voz generada por un algoritmo? y (b) si dice ser un familiar, ¿su voz coincide con la huella vocal que ese familiar registró previamente en el dispositivo?

Formulación divulgativa para presentación comercial: un guardián silencioso que escucha los primeros segundos de cada llamada y le avisa a la persona mayor, en pantalla y con letras grandes, cuando la voz que la está llamando no es la de su hijo o su nieto.

El producto mínimo viable queda definido por nueve funciones núcleo, que constituyen el alcance comprometido para la etapa semilla:

Cód.	Función núcleo	Descripción operativa
F1	Detección de voz sintética	Clasificación binaria (habla natural frente a habla generada por TTS o Voice Conversion) sobre una ventana de 2 segundos de audio neto del interlocutor, con modelo cuantizado en INT8.
F2	Verificación biométrica intrafamiliar	Comparación 1:1 (o 1:N acotada a un máximo de 8 plantillas) del embedding del interlocutor contra las huellas vocales de familiares enroladas y cifradas en el dispositivo.
F3	Identificación de números clasificados como spam o fraude	Consulta local e instantánea del número entrante contra una base cifrada de numeraciones ya categorizadas como spam, robocall, telemarketing o fraude, sincronizada periódicamente y enriquecida con reportes de la comunidad y señales de la operadora. Se detalla en el apartado 5.6.
F4	Palabras clave de seguridad	Definición de una palabra o frase secreta de identificación y de una palabra de coacción, acordadas dentro de la familia y reconocidas localmente durante la llamada, que aportan un factor de conocimiento independiente de la voz. Se detalla en el apartado 5.7.
F5	Protocolo de desafío intrafamiliar	Presentación en pantalla de una pregunta secreta acordada con la familia, que el usuario puede formular al interlocutor para desarticular el engaño.
F6	Alerta accesible durante la llamada	Superposición gráfica (overlay) de alto contraste sobre la pantalla de llamada, con cinco niveles de severidad y mensaje de lectura instantánea.
F7	Aviso al guardián	Notificación automática al teléfono del hijo o nieto designado cuando se dispara una alerta roja, con número, hora y nivel de riesgo (nunca con audio).
F8	Verificación diferida de audios	Análisis bajo demanda de mensajes de voz de WhatsApp o de un audio compartido a la aplicación, para el vector de fraude asincrónico.
F9	Configuración remota por el guardián	Panel que permite al familiar administrador enrolar voces, definir palabras clave y preguntas de desafío, y ajustar sensibilidad sin exigir destreza técnica a la persona protegida.

5.2. Alcance y no alcance del sistema (delimitación explícita)

La delimitación negativa del producto es tan relevante como la positiva, tanto por razones éticas y jurídicas como por gestión de expectativas del usuario:

VozReal SÍ hace	VozReal NO hace
Analiza acústicamente los primeros segundos de voz del interlocutor en el propio dispositivo.	No graba, no almacena ni transmite el audio de las llamadas en ningún momento ni bajo ninguna circunstancia.
Informa un nivel de riesgo probabilístico y sugiere una acción de verificación humana.	No emite veredictos absolutos ni afirma que una llamada sea "segura" o "falsa" en términos categóricos.
Entrega el control de la decisión a la persona usuaria y avisa a su familiar de confianza.	No corta ni rechaza llamadas de manera autónoma, con la única excepción del bloqueo silencioso de números ya clasificados como spam comercial, que el Guardián Administrador debe habilitar de forma expresa.
Almacena las huellas vocales cifradas exclusivamente en el teléfono de la persona protegida.	No constituye ni alimenta ninguna base de datos biométrica centralizada de ciudadanos.
Permite el uso por parte de personas sin alfabetización digital, delegando la configuración en un guardián.	No exige a la persona protegida instalar, configurar, actualizar ni interpretar información técnica.
Genera un registro local de eventos exportable por el usuario para facilitar la denuncia.	No reemplaza la denuncia penal, la intervención de las fuerzas de seguridad ni el asesoramiento legal.

5.3. El Círculo de Protección Familiar: a quién protege el producto

VozReal no se diseña para un usuario individual genérico sino para una unidad de uso que denominamos Círculo de Protección Familiar. Esta decisión de diseño resuelve simultáneamente el problema técnico (se necesita la voz de los familiares para poder compararla) y el problema comercial (la persona protegida no es la misma que la que descubre, instala y paga el producto).

Rol	Quién lo ocupa	Responsabilidad dentro del sistema
Usuario Protegido	El eslabón más vulnerable del grupo familiar.	Es quien tiene la aplicación activa en su teléfono y recibe las alertas. No configura nada, no administra nada, no necesita saber que la tecnología existe: solo ve un cartel grande cuando algo no está bien.
Guardián Administrador	Habitualmente un hijo, hija o nieto de entre 25 y 55 años.	Instala y configura la aplicación, enrola su propia voz y la de los demás familiares, define las preguntas de desafío, recibe los avisos de alerta roja y es el responsable del pago de la suscripción.
Voces Enroladas	Hasta ocho familiares del círculo íntimo.	Registran voluntariamente una muestra de voz de 30 segundos que se convierte en la plantilla biométrica de referencia contra la cual se compara cualquier llamada que invoque su identidad.

5.3.1. Perfil ampliado del Usuario Protegido

Si bien el núcleo de mercado y el caso de uso prioritario es el adulto mayor de 65 años o más, la definición del producto se establece deliberadamente en torno al concepto de vulnerabilidad situacional dentro del grupo familiar, lo que amplía el mercado direccionable sin modificar la arquitectura técnica:

- **Adultos mayores (segmento primario):** personas jubiladas o pensionadas, con teléfonos de gama baja o media, que atienden todas las llamadas entrantes y que constituyen el blanco preferencial del secuestro virtual y de la extorsión emocional.
- **Personas con deterioro cognitivo leve o demencia incipiente:** segmento en el que la capacidad de verificación crítica está comprometida de forma permanente y no solo bajo estrés agudo.
- **Personas con discapacidad intelectual o del desarrollo:** usuarios con autonomía telefónica pero con dificultades para detectar intenciones engañosas, para quienes la pregunta de desafío resulta un andamiaje cognitivo especialmente eficaz.
- **Adolescentes y menores con teléfono propio:** expuestos a grooming telefónico y a estafas de suplantación de figuras de autoridad familiar, donde la verificación de que quien llama es efectivamente el padre o la madre tiene valor preventivo directo.
- **Adultos con baja alfabetización digital:** población que, con independencia de la edad, carece del modelo mental necesario para concebir que una voz pueda ser sintetizada.

5.3.2. Enrolamiento de voces sin comprometer la privacidad

El enrolamiento es el punto crítico de fricción del producto y también el punto donde podría quebrarse la promesa de que ningún dato biométrico abandona el dispositivo. La solución adoptada es la siguiente:

1. **Enrolamiento remoto por enlace:** el Guardián Administrador envía por WhatsApp un enlace de invitación al familiar. Este graba 30 segundos de habla leyendo un texto propuesto, dentro de un módulo liviano que se ejecuta en su propio teléfono.
2. **Extracción local del embedding:** el audio se procesa y se descarta en el dispositivo del familiar. Nunca se transmite audio. Lo único que viaja es el vector de 128 dimensiones resultante.
3. **Transporte cifrado extremo a extremo:** ese vector se cifra con la clave pública del dispositivo de la persona protegida y se transmite mediante un relay ciego que no puede descifrarlo y que destruye el paquete en cuanto se confirma la entrega.
4. **Alternativa presencial sin conectividad:** en la próxima visita, el familiar graba los 30 segundos directamente en el teléfono de la persona protegida, sin que intervenga ningún servidor.
5. **Refuerzo adaptativo:** cada llamada confirmada por el usuario como auténtica puede incorporarse opcionalmente para refinar la plantilla local, mejorando la robustez frente al canal telefónico y al envejecimiento vocal.

5.4. Decisión de arquitectura de entrega: aplicación, servicio de red o modelo híbrido

La consigna exige decidir si VozReal será una aplicación, un servicio prestado sobre la línea telefónica o una colaboración entre ambos. Para fundamentar la decisión se evaluaron las tres alternativas contra ocho criterios de negocio y de ingeniería:

Criterio de evaluación	A. Solo aplicación	B. Solo servicio de red	C. Modelo híbrido
Tiempo de salida al mercado	Alto (3 a 6 meses)	Bajo (12 a 24 meses de negociación e integración)	Alto en fase 1, escalable en fase 2
Cobertura de dispositivos	Android 8 en adelante, parque masivo	Total, incluso líneas fijas y feature phones	Total en régimen
Acceso al flujo de audio	Limitado por API (mitigado con altavoz)	Completo en el core de red	Completo mediante app privilegiada de operadora
Cumplimiento de la Ley 25.326	Óptimo (sin base centralizada)	Crítico (base biométrica centralizada)	Óptimo (la biometría no sale del dispositivo)
Cobertura de WhatsApp y VoIP	Parcial, vía micrófono y análisis diferido	Nula (cifrado extremo a extremo)	Parcial, la mejor alcanzable

Criterio de evaluación	A. Solo aplicación	B. Solo servicio de red	C. Modelo híbrido
Costo de adquisición de usuarios	Muy alto (marketing directo)	Muy bajo (base instalada de la operadora)	Decreciente por fases
Mecanismo de cobro	Tarjeta o tienda de aplicaciones (barrera real para el segmento)	Cargo en factura telefónica	Ambos, según canal
Dependencia de terceros	Baja	Total y bloqueante	Baja en fase 1, compartida en fase 2

DECISIÓN ADOPTADA: MODELO HÍBRIDO SECUENCIAL (APP-FIRST, CARRIER-ENABLED)

VozReal se define como una aplicación móvil Android con arquitectura Edge AI, que constituye el producto núcleo y funciona de forma completa y autónoma sin ningún acuerdo con operadoras, y que está diseñada desde su concepción para ser integrada, en una segunda fase, como servicio de valor agregado de las compañías de telefonía móvil.

No es un servicio de red puro ni una aplicación aislada: es una aplicación cuya propuesta de valor se potencia con el acuerdo con la operadora, pero que no depende de él para existir ni para proteger al usuario.

La biometría de voz permanece siempre en el dispositivo. La asociación con la línea telefónica aporta distribución, cobro, permisos privilegiados de sistema y señales de red, pero nunca huellas vocales ni audio.

5.4.1. Fundamentos del descarte de las alternativas puras

Se descarta la alternativa B (servicio de red puro) por tres razones dirimentes. Primero, el procesamiento de voz en el núcleo de la red obligaría a constituir exactamente el honey pot biométrico que el apartado 2.3 identifica como riesgo catastrófico, contradiciendo el principio de minimización del artículo 4 de la Ley 25.326. Segundo, las llamadas de WhatsApp, que concentran un volumen creciente del fraude en Argentina, viajan cifradas de extremo a extremo y resultan técnicamente inaccesibles desde la red de la operadora. Tercero, un proyecto en etapa pre-semilla que condiciona su existencia comercial a la firma de un contrato con una operadora de telecomunicaciones asume un riesgo de ejecución inaceptable, con ciclos de venta corporativos de entre 12 y 24 meses y sin ingreso alguno hasta su cierre.

Se descarta igualmente la alternativa A (aplicación aislada como estrategia definitiva) porque renuncia a activos que solo la operadora puede aportar: la resolución del acceso al flujo de audio bajo Android 10 y posteriores mediante permisos de sistema privilegiados, el cobro en factura, que elimina la principal barrera de conversión en el segmento de adultos mayores, y un conjunto de señales de señalización de red inaccesibles para cualquier aplicación de terceros.

5.5. Capa 0: la asociación con la línea telefónica

La alianza con operadoras introduce una capa de análisis previa a las tres ya descritas, denominada Capa 0, que opera exclusivamente sobre metadatos de señalización y no sobre contenido de audio. Su valor reside en que aporta indicios de fraude antes de que la llamada sea siquiera atendida.

Señal de red aportada por la operadora	Indicio que revela	Uso en el motor de decisión
Antigüedad de la línea originante menor a 72 horas	SIM prepaga descartable adquirida para cometer el ilícito	Eleva el nivel base de precaución y activa siempre las Capas 2 y 3
Cambio reciente de IMSI o SIM en la línea de un familiar enrolado	Posible SIM swap o secuestro de identidad de la línea	Inhabilita la verificación en verde por número y exige verificación de voz
Cabecera nacional con enrutamiento de origen internacional o VoIP mayorista	Falsificación de Caller ID, principal punto ciego de la competencia	Indicio fuerte, escala directamente el nivel de alerta

Señal de red aportada por la operadora	Indicio que revela	Uso en el motor de decisión
Densidad de llamadas del originante en la última hora (fan-out)	Campaña de robocalling o marcación predictiva masiva	Clasifica la llamada como automatizada o comercial
Cruce en tiempo real con líneas denunciadas en la red de la operadora	Reputación fresca, sin la ventana de impunidad de las bases colaborativas	Complementa y actualiza la Capa 1 de reputación local
Correlación con rangos de numeración asociados a fraude	Patrones de originación identificados junto a las autoridades competentes	Ajuste de umbrales por contexto geográfico

5.5.1. Qué aporta cada parte en la alianza

- **Aporta la operadora:** base instalada de abonados, cobro en factura, permisos de sistema privilegiados para una aplicación preinstalada y firmada (lo que habilita el acceso legítimo a la fuente de audio de llamada), señales de señalización de red y canales de atención presencial en sucursales, donde el personal puede enrolar la voz del familiar que acompaña al adulto mayor.
- **Aporta VozReal:** los modelos de anti-spoofing y biometría vocal, la experiencia de usuario gerontológica, el cumplimiento normativo por diseño, un flujo agregado y anonimizado de reportes de fraude que mejora la inteligencia de red de la propia operadora, y un servicio diferencial que reduce la rotación de clientes en el segmento de mayor antigüedad y menor propensión a la portabilidad.
- **Nunca se delega a la operadora:** las plantillas biométricas, el audio de las llamadas y el contenido de las conversaciones. Este límite es contractual, arquitectónico e innegociable, y constituye el eje de la comunicación pública del producto.

5.5.2. Modalidades de acuerdo y modo de red asistida

1. **Paquete en plan familiar:** VozReal se ofrece como adicional de bajo costo en planes multilínea, con reparto de ingresos y cargo en la factura del titular, que habitualmente es el propio Guardián Administrador.
2. **Preinstalación en equipos:** acuerdo con la operadora o directamente con fabricantes (Samsung, Motorola, Xiaomi) para incorporar la aplicación en las gamas de entrada más vendidas al segmento sénior.
3. **Modo de red asistida (fase de crecimiento):** para abonados sin smartphone (telefonía fija o feature phones), la operadora puede ejecutar únicamente las Capas 0 y 1 en su infraestructura y notificar el riesgo mediante un SMS al Guardián Administrador. Debe subrayarse ante el cuerpo evaluador que en este modo degradado no existe biometría ni análisis acústico alguno, precisamente porque la plantilla vocal nunca abandona el dispositivo del usuario. Es una prestación complementaria de cobertura, no el producto.

5.6. Identificación de números clasificados como spam o fraude

La Capa 1 del sistema resuelve el caso más frecuente y menos sofisticado del universo de llamadas no deseadas: aquellas que provienen de numeraciones que alguien, en algún lugar, ya identificó y clasificó. Es la capa más barata en cómputo, la más rápida (se resuelve antes de que el teléfono termine de sonar) y la única que puede actuar sin que el usuario atienda.

5.6.1. Fuentes de clasificación

- **Base propia precargada:** conjunto inicial de prefijos, rangos de numeración y números individuales ya reportados, distribuido con la aplicación para que funcione desde el primer minuto, incluso sin conexión de datos.

- **Reportes de la comunidad de usuarios:** al finalizar una llamada, el usuario o su guardián pueden marcarla con un toque como spam comercial, robocall o intento de estafa. Los reportes se ponderan por la reputación histórica del reportante para evitar el envenenamiento deliberado de la base.
- **Registros públicos y oficiales:** incorporación de listados del Registro Nacional No Llame, alertas publicadas por entidades bancarias sobre numeraciones usadas para suplantarlas y tipologías difundidas por la UFECI y por las divisiones provinciales de ciberdelitos.
- **Señales de la operadora (Capa 0):** en el marco del acuerdo descrito en el apartado 5.5, líneas denunciadas en tiempo real y patrones de marcación masiva detectados en la red, que eliminan la ventana de impunidad de las líneas recién activadas.
- **Reglas heurísticas de formato:** detección de numeraciones no asignadas por el plan nacional, prefijos internacionales inusuales para el perfil del usuario, números de longitud anómala y cabeceras vacías u ocultas.

5.6.2. Consulta local y privacidad de la agenda

La diferencia estructural frente a Truecaller y Hiya es que VozReal no envía el número entrante a ningún servidor para preguntarle si es spam. La base se descarga cifrada al dispositivo y se sincroniza de forma diferencial, y toda consulta se resuelve localmente sobre un índice B-Tree en SQLite en menos de 20 milisegundos. La aplicación tampoco sube la agenda de contactos del usuario en ningún momento ni bajo ninguna forma, y los reportes comunitarios se transmiten disociados del identificador del reportante. En consecuencia, el sistema funciona íntegramente sin conexión de datos y no genera un registro externo de con quién habla la persona protegida.

5.6.3. Categorías y respuesta del sistema

Categoría	Criterio de asignación	Respuesta de la aplicación
Spam comercial o telemarketing	Reportes convergentes de múltiples usuarios sobre una misma numeración con actividad sostenida.	Etiqueta en la pantalla de llamada entrante y, si el guardián lo habilitó expresamente, bloqueo silencioso sin repique.
Robocall o marcación automatizada	Alta densidad de llamadas del originante en ventana corta y detección de habla sintética en llamadas previas.	Nivel 3 (naranja) con botón de cortar, bloquear y reportar.
Fraude bancario o institucional reportado	Numeración incluida en alertas oficiales o reportada como suplantación de un banco, organismo o fuerza de seguridad.	Nivel 3 (naranja) con advertencia explícita de que ninguna entidad solicita claves ni transferencias por teléfono.
Línea de reciente activación	Señal de Capa 0 sobre antigüedad menor a 72 horas o ausencia total de historial.	Nivel 2 (amarillo) y activación obligatoria de las Capas 2 y 3 al atender.
Numeración asociada a extorsión denunciada	Cruce con reportes de secuestro virtual validados por el equipo o por las autoridades.	Nivel 4 (rojo) desde el repique, antes de que el usuario atienda.
Contacto institucional legítimo verificado	Numeración oficial confirmada de bancos, obras sociales, organismos previsionales o servicios de emergencia.	Etiqueta verde informativa, sin que ello sustituya el análisis acústico posterior.

5.6.4. Límite reconocido de esta capa

Resulta metodológicamente honesto explicitar que esta funcionalidad, por sí sola, no protege contra el ataque que motiva el proyecto. Una base de reputación es inútil frente a una línea comprada media hora antes y absolutamente ciega frente a la falsificación de cabecera SIP, donde el número mostrado es el verdadero número del hijo de la víctima. Por eso la identificación de números spam es en VozReal una capa de higiene y de valor percibido inmediato, no la propuesta de valor central: filtra el ruido cotidiano para que las capas acústicas y el factor de conocimiento puedan concentrarse en el ataque dirigido.

5.7. Palabras clave de seguridad: el factor de conocimiento compartido

La biometría responde a la pregunta de algo que uno es, y la reputación del número a la de algo que uno tiene. Ninguno de esos dos factores resiste el escenario límite del proyecto: una clonación de altísima fidelidad emitida desde un número suplantado. VozReal incorpora por ello un tercer factor, algo que uno sabe, mediante una palabra o frase secreta acordada de antemano dentro del Círculo de Protección Familiar. Es la transposición al ámbito doméstico del principio de autenticación multifactor, y posee una ventaja decisiva sobre cualquier modelo acústico: un algoritmo generativo puede replicar un timbre de voz con precisión indistinguible, pero no puede conocer un secreto que nunca circuló por Internet.

5.7.1. Tipos de palabra clave

Tipo	Definición y uso	Efecto en el sistema
Palabra de identificación (positiva)	Frase breve acordada por la familia que el familiar pronuncia al comienzo de cualquier llamada urgente o inesperada, por ejemplo "cielo naranja". Es la misma para todo el círculo, a fin de reducir la carga mnémica de la persona protegida.	Su detección eleva la confianza y habilita el nivel 0 reforzado, siempre que la Capa 2 no detecte síntesis. Su ausencia, por sí sola, no penaliza.
Palabra de coacción (duress word)	Término acordado que el familiar introduce en la conversación cuando está hablando obligado bajo amenaza. Es un pedido de auxilio encubierto que el atacante no puede reconocer como tal.	Dispara el nivel 4 en modo discreto, aunque la voz sea auténtica: avisa al guardián sin desplegar un cartel que pueda delatar al usuario frente al interlocutor.
Pregunta de desafío (interrogativa)	Pregunta cuya respuesta solo conoce el familiar real, configurada previamente y sugerida en pantalla por la aplicación cuando se dispara una alerta.	No la evalúa el sistema sino la persona. Traslada la conversación del plano emocional al analítico y es el recurso de última instancia.

5.7.2. Implementación técnica: reconocimiento local de vocabulario cerrado

- **Keyword Spotting on-device:** el reconocimiento se realiza mediante un modelo de detección de palabras clave de vocabulario cerrado, del orden de 1 MB cuantizado en INT8, que opera sobre una ventana deslizante con latencia inferior a 100 milisegundos y consumo despreciable.
- **Diferencia esencial con la transcripción semántica:** a diferencia del enfoque de Google analizado en el apartado 4.2.3, VozReal no transcribe la conversación. El modelo embebido solo es capaz de reconocer el conjunto cerrado de términos que la familia definió; no existe en el dispositivo ningún motor de reconocimiento de habla general, por lo que reconstruir el contenido de la llamada es técnicamente imposible, no solamente una promesa de política de privacidad.
- **Almacenamiento seguro:** la palabra se guarda como plantilla acústica y como hash, cifrada con AES-GCM de 256 bits bajo el Android Keystore. No se conserva en texto plano legible ni se muestra completa en la pantalla de la persona protegida, que solo accede a una pista configurable.
- **Criterios de robustez:** se recomiendan frases de dos a cuatro sílabas, de baja frecuencia en el habla cotidiana, para minimizar activaciones espurias, y el modelo se calibra con tolerancia a variaciones de pronunciación, entonación emocional y degradación del canal telefónico.
- **Encadenamiento con el anti-spoofing:** la palabra correcta nunca basta por sí sola. Si la Capa 2 detecta artefactos de síntesis, el indicio físico prevalece sobre el factor de conocimiento, de modo que un atacante que hubiese obtenido la palabra por filtración tampoco logra una validación en verde.

5.7.3. Gobernanza familiar y buenas prácticas

El asistente de configuración incorpora estas reglas de forma explícita, dado que la seguridad del mecanismo depende íntegramente de la disciplina del grupo familiar:

- Acordar la palabra en persona, nunca por WhatsApp, SMS, correo electrónico ni redes sociales.
- No utilizar datos deducibles del entorno digital de la familia, como el nombre de una mascota publicada, un apodo conocido o una fecha divulgada en redes.
- Rotar la palabra de identificación de forma semestral, con recordatorio automático de la aplicación.
- No ensayar ni mencionar jamás la palabra de coacción fuera del acuerdo original, ni en la misma conversación en que se define la de identificación.
- Enseñar a la persona protegida una sola regla operativa, deliberadamente simple: si alguien llama pidiendo dinero con urgencia y no dice la palabra, hay que cortar y devolver el llamado al número de la agenda.

5.7.4. Integración con el motor de decisión

Situación detectada	Nivel resultante	Comportamiento de la aplicación
Palabra de identificación correcta, voz coincidente y sin indicios de síntesis	Nivel 0 reforzado	Banda verde con la leyenda "Verificado por voz y palabra clave".
Palabra de identificación correcta pero habla sintética detectada	Nivel 4 (rojo)	Prevalece el indicio físico. Se informa que la palabra fue dicha pero la voz no es humana.
Palabra de coacción detectada	Nivel 4 en modo discreto	Aviso inmediato y silencioso al guardián, sin cartel visible que pueda delatar al usuario ante el interlocutor.
Ausencia de palabra clave en una llamada urgente de un familiar	No modifica el nivel por sí sola	La aplicación ofrece el botón "Pedile la palabra clave", que despliega la instrucción en letra grande.
Palabra incorrecta tras solicitud explícita del usuario	Escala a nivel 4 (rojo)	Se despliega la pregunta de desafío y el botón de aviso al guardián.
Palabra clave dicha por un número desconocido no enrolado	Nivel 2 (amarillo)	Se advierte que la palabra pudo haberse filtrado y se exige verificación biométrica o pregunta de desafío.

5.8. Sistema de alertas: el semáforo cognitivo de cinco niveles

El sistema de alertas es la superficie donde toda la ingeniería precedente se vuelve útil o inútil. Se define una escala de cinco niveles de severidad, más un estado posterior a la llamada. Cada nivel especifica de forma inequívoca su disparador, su representación visual, su retroalimentación háptica y la acción sugerida al usuario.

Nivel	Disparador	Manifestación en pantalla	Acción ofrecida
0. VERDE. Voz verificada	La voz coincide con una plantilla familiar por encima del umbral alto de confianza y no se detectan artefactos de síntesis.	Banda verde delgada en el borde superior con el nombre y la foto del familiar y la leyenda "Voz verificada: Marcela". Sin sonido ni vibración.	Ninguna. El sistema se limita a tranquilizar y desaparece a los pocos segundos.
1. GRIS. Sin datos	Número desconocido sin señales adversas de ningún tipo. Estado por defecto de la mayoría de las llamadas.	Sin superposición alguna. Silencio de interfaz deliberado para evitar fatiga de alerta.	Ninguna.
2. AMARILLO. Precaución	Score ambiguo, audio insuficiente o degradado, número sin reputación o línea activada en las últimas 72 horas.	Banda ámbar de una línea: "No pudimos verificar quién está hablando".	Sugerencia de poner el altavoz para mejorar el análisis y botón para solicitar la pregunta de desafío.

Nivel	Disparador	Manifestación en pantalla	Acción ofrecida
3. NARANJA. Llamada automatizada o comercial	Se detecta habla sintética o patrón de robocall en un número que no está asociado a ningún familiar enrolado.	Banda naranja: "Esto parece un robot, no una persona". Doble vibración corta.	Botones de cortar y bloquear, y de reportar el número a la base comunitaria.
4. ROJO. Posible suplantación de un familiar	La llamada invoca la identidad de un familiar (por número o por mención explícita de parentesco) y la voz presenta artefactos de síntesis o no alcanza el umbral de similitud biométrica.	Superposición de pantalla completa, alto contraste, tipografía de 28sp o superior: "Atención: esta voz no suena como la de tu hija Marcela". Vibración larga y tono discreto.	Botón para pedir la palabra clave, pregunta de desafío en pantalla, aviso inmediato al guardián y botón de cortar. El sistema nunca corta por su cuenta.
5. MODO RESGUARDO (posterior a la llamada)	Se activa automáticamente al finalizar cualquier llamada que haya alcanzado el nivel rojo.	Pantalla de contención con tres instrucciones en lenguaje llano y letra grande.	No transferir dinero ni entregar objetos; llamar al familiar al número guardado en la agenda; avisar al guardián y exportar el registro del evento para la denuncia.

5.8.1. Principios de diseño de la alerta

- **Una sola idea por alerta:** la superposición comunica un único mensaje legible en menos de dos segundos. No se muestran porcentajes, puntajes ni terminología técnica a la persona protegida, aunque el detalle técnico queda disponible para el guardián en su propio panel.
- **Nunca acusar, siempre invitar a verificar:** el mensaje no afirma que el interlocutor sea un delincuente. Afirma que el sistema no pudo confirmar que sea quien dice ser y propone una acción concreta. Esta formulación protege al usuario de la vergüenza de desconfiar de un hijo real y protege al producto de la asimetría reputacional del falso positivo.
- **Alerta por canal privado (modo susurro):** dado que más del 70% de los adultos mayores atiende en altavoz y no necesariamente mira la pantalla, el nivel rojo puede reproducir el mensaje en un volumen bajo dirigido exclusivamente al auricular del dispositivo, inaudible para el interlocutor. Es una vía de aviso que no delata al usuario frente al atacante.
- **No interferir con la aplicación de teléfono:** la superposición nunca cubre el botón de colgar ni altera los controles nativos del sistema operativo, requisito tanto de usabilidad como de cumplimiento de las políticas de Google Play.
- **Accesibilidad certificable:** contraste conforme a WCAG 2.2 nivel AAA, compatibilidad con TalkBack y con escalado de fuente del sistema, y ausencia de dependencia exclusiva del color para transmitir la severidad, que se refuerza con íconos y texto.

5.9. Lógica de decisión: cómo determina el sistema que hay spam o fraude

El motor no promedia ciegamente las salidas de las capas. Opera como una cascada con activación condicional (gating), donde cada etapa se ejecuta solo si es necesaria, respetando el presupuesto de cómputo móvil, y donde la escalada de severidad es asimétrica.

1. **Evaluación previa a la atención (Capas 0 y 1):** antes de que el usuario descuelgue, el sistema consulta localmente la base de números ya clasificados como spam o fraude descrita en el apartado 5.6 y, si hay acuerdo con la operadora, las señales de red. Esta etapa fija un nivel base de precaución y determina si el número corresponde a un familiar enrolado.
2. **Captura y detección de actividad vocal:** al atenderse la llamada, un detector de actividad vocal aísla 2 segundos de habla neta del interlocutor, descartando silencios, tonos y ruido de línea.
3. **Capa 2, anti-spoofing (siempre se ejecuta):** el clasificador devuelve una probabilidad de que el habla sea sintética, junto con un indicador de calidad de la muestra.

4. **Capa 3, biometría (ejecución condicional):** se activa si el número pertenece a un familiar enrolado, o si un detector local de palabras clave de parentesco identifica expresiones como "mamá", "abuela", "soy tu hijo" o "soy tu nieto" en un número desconocido. En este último caso la comparación es 1:N contra las ocho plantillas registradas, no contra una base externa.
5. **Factor de conocimiento (palabra clave):** en paralelo, el detector de vocabulario cerrado vigila la aparición de la palabra de identificación o de la palabra de coacción definidas en el apartado 5.7, y su resultado ingresa al motor como una entrada independiente de la acústica.
6. **Fusión con escalada asimétrica:** cualquier capa puede elevar el nivel de alerta, pero ninguna puede reducirlo a verde por sí sola. El verde exige simultáneamente una similitud biométrica por encima del umbral alto y una probabilidad de síntesis por debajo del umbral bajo. Ante calidad de muestra insuficiente, el sistema nunca devuelve verde: devuelve amarillo.

La siguiente matriz resume la resolución del motor en los nueve casos posibles de combinación entre la Capa 2 y la Capa 3:

Capa 2 (anti-spoofing) / Capa 3 (biometría)	Coincide con familiar	No coincide con familiar	No aplica (sin candidato)
Habla natural	NIVEL 0 (verde)	NIVEL 4 (rojo)	NIVEL 1 o 2 según reputación
Habla sintética detectada	NIVEL 4 (rojo). Prevalece el indicio de síntesis aunque el timbre sea clonado con fidelidad	NIVEL 4 (rojo)	NIVEL 3 (naranja)
Resultado indeterminado o muestra de baja calidad	NIVEL 2 (amarillo)	NIVEL 2 o 4 según señales de Capa 0 y 1	NIVEL 2 (amarillo)

Los umbrales de decisión se fijan sobre la curva DET obtenida del corpus local descrito en el apartado 8.2, con un punto de operación deliberadamente conservador para el nivel rojo. La asimetría de los errores impone esta elección: el nivel amarillo funciona como amortiguador de la incertidumbre, absorbiendo los casos dudosos que de otro modo se convertirían en falsos positivos rojos.

5.10. Flujo operativo completo del producto

Momento	Qué ocurre	Quién interviene
Configuración inicial (una sola vez)	Instalación, concesión de permisos de accesibilidad y superposición, enrolamiento de voces familiares y definición de las preguntas de desafío.	El Guardián Administrador, presencialmente o de forma remota. La persona protegida no realiza ninguna acción técnica.
Llamada entrante	Evaluación de Capas 0 y 1 antes del descuelgue. El identificador de llamada se enriquece con el estado de reputación.	Sistema, de forma automática y silenciosa.
Primeros 3 segundos de conversación	Captura de 2 segundos de habla neta, ejecución de las Capas 2 y 3 y fusión de resultados.	Sistema. El usuario no percibe nada hasta que hay algo que informar.
Alerta	Despliegue del nivel correspondiente del semáforo cognitivo, con su mensaje, su retroalimentación háptica y sus acciones.	Sistema informa, persona usuaria decide. Nunca a la inversa.
Verificación humana	Formulación de la pregunta de desafío al interlocutor y resolución de la situación por parte del usuario.	Persona protegida, asistida por el texto en pantalla.

Momento	Qué ocurre	Quién interviene
Cierre y contención	Modo Resguardo, aviso al guardián, registro local del evento y exportación opcional de evidencia para la denuncia.	Sistema, Guardián Administrador y, eventualmente, las fuerzas de seguridad.

5.11. Política de falsos positivos y casos borde

El falso positivo no es un error estadístico menor sino un riesgo reputacional y afectivo: alertar sobre una llamada legítima de un hijo real siembra desconfianza intrafamiliar y conduce a la desinstalación. Se establecen cuatro mecanismos de mitigación:

- **Techo de severidad por calidad de señal:** si la relación señal a ruido de la muestra está por debajo del mínimo operativo, el nivel máximo que el sistema puede emitir queda limitado a amarillo, con independencia de los puntajes obtenidos.
- **Histéresis y confirmación del usuario:** si tras una alerta el usuario o el guardián confirman que la llamada era auténtica, el sistema no reitera el mismo nivel para ese número durante un período configurable e incorpora opcionalmente la muestra al refuerzo adaptativo de la plantilla.
- **Tolerancia a variabilidad fisiológica y de canal:** el modelo se calibra con muestras que incluyan resfríos, afonía, llanto, uso de manos libres, altavoz de automóvil y códecs degradados, condiciones todas que alteran el embedding sin implicar suplantación.
- **Transparencia frente al error:** toda alerta roja incluye un acceso directo a la opción "era mi familiar", que además de ajustar el comportamiento local alimenta, de forma agregada y anónima, la mejora de los umbrales del modelo.

5.12. Modelo comercial y canales derivados de la decisión

Canal	Modelo	Comprador	Hipótesis de valor a validar
Directo (B2C)	Freemium en Google Play	El hijo o nieto que descarga y configura	Versión gratuita con Capas 1 y 2 y una sola voz enrolada; plan familiar por suscripción mensual con hasta ocho voces y aviso al guardián
Operadoras (B2B2C)	Servicio de valor agregado con reparto de ingresos	El abonado, con cargo en factura	Elimina la barrera de pago con tarjeta y multiplica el alcance sobre el segmento objetivo
Fabricantes (B2B)	Licenciamiento por dispositivo	El OEM	Diferencial competitivo en gamas de entrada orientadas al público sénior
Instituciones (B2B / B2G)	Licencia corporativa o convenio	Bancos, mutuales, obras sociales, organismos previsionales y municipios	Reducción de pérdidas por fraude y cumplimiento de programas de protección al adulto mayor

6. MARCO REGULATORIO, NORMATIVO Y ÉTICO

6.1. Protección de datos personales en Argentina: Ley Nacional N° 25.326

Cualquier sistema que procese señales de habla humana interactúa de manera directa con el régimen jurídico de los datos personales. En la República Argentina, la Ley 25.326 y las directivas de la Agencia de Acceso a la Información Pública (AAIP) establecen directrices terminantes:

- **Naturaleza sensible de los datos biométricos:** el vector de características de voz (voice embedding) es un dato personal biométrico que permite la identificación unívoca e indubitable de un ser humano. Conforme a los artículos 2 y 8 de la ley, los datos sensibles gozan de una tutela jurídica reforzada, prohibiéndose su recopilación salvo que medie consentimiento expreso, libre e informado del titular, o razones de seguridad pública legalmente fundadas.
- **El principio de privacidad por diseño en VozReal:** al implementar una arquitectura Edge AI donde las plantillas biométricas se generan y almacenan de forma local en el dispositivo del usuario, VozReal cumple de raíz con los principios de minimización de datos (artículo 4). La empresa u operadora no actúa como responsable ni encargada de tratamiento de bases de datos biométricas centralizadas, eliminando la obligación de registro masivo de bases y neutralizando la posibilidad de fugas de datos que comprometan a los familiares enrolados.
- **Criptografía local y derecho al olvido:** los vectores de voz almacenados en el teléfono se cifran mediante algoritmos simétricos estándar (AES-GCM de 256 bits) utilizando claves gestionadas por el módulo de hardware seguro del dispositivo (Android Keystore System / StrongBox). En concordancia con el artículo 16 de la Ley 25.326, la aplicación provee un botón de eliminación inmediata que destruye tanto el vector como la clave criptográfica asociada cuando el usuario así lo decida.
- **Consentimiento del familiar enrolado:** la persona cuya voz se registra como plantilla de referencia es un titular de datos distinto del usuario de la aplicación. El flujo de enrolamiento descrito en el apartado 5.3.2 incorpora por ello un consentimiento expreso, informado y revocable de cada familiar, con posibilidad de eliminar su plantilla de forma remota en cualquier momento.
- **Alcance del acuerdo con operadoras:** en el modelo híbrido adoptado, la operadora actúa exclusivamente como canal de distribución y como proveedora de metadatos de señalización que ya trata legítimamente en el marco de su prestación. No accede a plantillas biométricas ni a contenido de audio, por lo que no se configura una cesión de datos sensibles en los términos del artículo 11 de la ley.

6.2. Marco regulatorio de telecomunicaciones: ENACOM y protocolos de red

En el ámbito de las telecomunicaciones, regulado por el Ente Nacional de Comunicaciones (ENACOM) mediante la Ley N° 27.078 (Argentina Digital):

- **La vulnerabilidad estructural de la red pública (PSTN):** la red telefónica tradicional no fue diseñada con capas criptográficas de autenticación de origen. El estándar internacional STIR/SHAKEN (desarrollado por la IETF y la alianza ATIS), que exige que cada proveedor de telecomunicaciones firme criptográficamente el identificador de llamada para certificar que el emisor tiene derecho legítimo a usar dicho número, no se encuentra implementado con carácter vinculante en las redes móviles de Argentina ni de América Latina.
- **Justificación técnica de una solución en el dispositivo receptor (client-side):** ante la imposibilidad fáctica de que las empresas de telecomunicaciones resuelvan la suplantación de cabecera SIP a corto plazo, la defensa activa debe implementarse en el punto final de la comunicación: el smartphone del abonado. Esta constatación es, precisamente, el fundamento regulatorio de la decisión de arquitectura adoptada en el apartado 5.4.
- **Encuadre del servicio de valor agregado:** la comercialización de VozReal a través de una operadora se encuadra como servicio de valor agregado sobre la prestación básica, modalidad contemplada por el régimen vigente y que no requiere licencia TIC propia por parte del proveedor de la solución.

6.3. Principios éticos y responsabilidad algorítmica

La implementación de un asistente de seguridad en llamadas impone dilemas éticos fundamentales que deben gobernarse con criterios deontológicos estrictos:

- **Gestión de la asimetría del error:** un falso negativo (no detectar una voz clonada) tiene un costo potencial catastrófico: el despojo económico total o un trauma psicológico severo para una familia. Sin

embargo, un falso positivo descontrolado (alertar sobre una llamada legítima de un hijo real con mala señal de audio) genera un estado de paranoia angustiante e induce desconfianza intrafamiliar. Por ello, la política de umbrales del modelo calibra un punto de operación conservador y siempre enmarca la alerta como probabilidad y jamás como veredicto indiscutible.

- **Soberanía y no intervención automática:** VozReal adopta el principio ético de "la IA informa, el humano decide". La aplicación tiene estrictamente vedado cortar la llamada o colgar el teléfono de manera autónoma. La decisión de continuar la charla, formular la pregunta de desafío o interrumpir la comunicación corresponde íntegramente a la persona usuaria.
- **No estigmatización acústica:** los modelos de verificación de locutor pueden presentar sesgos de desempeño según edad, sexo, acento regional o patologías de la voz. El corpus de calibración incorpora deliberadamente variedad dialectal del NOA y voces con alteraciones fonatorias, y el desempeño se reporta desagregado por subgrupo para evitar que el sistema alerte de forma desproporcionada sobre determinados perfiles de hablante.
- **Dignidad del usuario protegido:** el sistema se diseña para asistir sin infantilizar. El Guardián Administrador recibe avisos de riesgo, no un registro de la vida telefónica de su familiar: no accede a la lista de llamadas, ni a su duración, ni a su contenido. La vigilancia familiar encubierta es un uso explícitamente excluido del producto.

7. VIABILIDAD TÉCNICA Y DESAFÍOS DE IMPLEMENTACIÓN EN ANDROID

7.1. Diagrama de flujo del pipeline tecnológico on-device

El funcionamiento interno de VozReal se estructura en un flujo secuencial asíncrono y ultraeficiente que opera en cinco etapas consecutivas:

Fase del pipeline	Operación técnica en el teléfono	Tecnología o algoritmo	Latencia estimada
Fase 1: ingesta y VAD	Al descolgar, se captura el flujo entrante y se activa un detector de actividad vocal para descartar silencios y ruidos de línea.	Silero VAD o WebRTC VAD cuantizado en TFLite.	100 a 150 ms
Fase 2: Capa 1 (reputación)	Cruce simultáneo del identificador numérico contra una base local SQLite de prefijos maliciosos y reportes comunitarios sincronizados.	Indexación B-Tree sobre SQLite local cifrado.	Menos de 20 ms
Fase 3: Capa 2 (anti-spoofing)	Se extraen 2.0 segundos de habla neta del emisor. El modelo analiza la coherencia de fase y las micro-respiraciones buscando artefactos de síntesis por IA.	AASIST-Lite o MobileRawNet cuantizado a INT8 vía ONNX Mobile.	400 a 650 ms (SoC ARMv8)
Fase 4: Capa 3 (verificación)	Si el número o la llamada se asocia a un contacto familiar registrado, se genera el vector de locutor y se compara con la huella local guardada.	Tiny-ECAPA-TDNN (embedding de 128 dimensiones) y similitud coseno.	250 a 400 ms
Fase 5: notificación accesible	Superposición gráfica de alerta en la pantalla de llamada con semiótica de color y pregunta familiar recomendada.	Android WindowManager Overlay Service (API de accesibilidad).	Menos de 50 ms

TIEMPO TOTAL ACUMULADO DEL PIPELINE

El tiempo total desde que la persona atiende y el emisor emite su primera frase de 2 segundos hasta el despliegue de la alerta en pantalla oscila entre 820 ms y 1.250 ms, cumpliendo con creces la meta operativa de alertar al

> usuario antes de los primeros 3 segundos de conversación.
>
> La Capa 0 descrita en el apartado 5.5 no incrementa este presupuesto, dado que se resuelve antes del descuelgue y de forma paralela al repique de la llamada.

7.2. El desafío del acceso al flujo de audio en Android moderno (Android 10 a 15)

Uno de los desafíos técnicos más rigurosos que debe defender el equipo ante evaluadores de ingeniería reside en las políticas de seguridad de Google Android relativas a la privacidad del audio en llamadas:

- **Deprecación de la fuente VOICE_CALL:** a partir de Android 10, Google restringió el uso de la fuente de audio telefónica en la API estándar AudioRecord para aplicaciones de terceros, impidiendo la grabación bidireccional directa de llamadas en segundo plano para evitar malware espía.

Ruta de solución técnica para la etapa de prototipado y validación:

1. **Modo asistido por altavoz o manos libres:** en el segmento de personas mayores, un porcentaje superior al 70% acostumbra a atender las llamadas en modo altavoz debido a dificultades auditivas presbiacúsicas. En esta modalidad, el micrófono ambiental del dispositivo captura con nitidez la voz del emisor reproducida por el altavoz, permitiendo el análisis acústico sin restricciones de API.
2. **Servicio de accesibilidad (AccessibilityService API):** utilizado para la detección de eventos de inicio de llamada y la proyección de capas superpuestas informativas de alta visibilidad que no interfieran con la aplicación de teléfono predeterminada del sistema operativo.
3. **Integración a nivel de operadora o ROM de fabricante (visión de etapa de crecimiento):** para la escala masiva, la integración se proyecta como un servicio licenciado a operadores telefónicos o fabricantes, quienes disponen de permisos de sistema privilegiados para auditar el flujo de señal antes del renderizado de audio. Esta es, en el plano técnico, la principal razón de ingeniería que justifica la alianza con la línea telefónica resuelta en el apartado 5.4.

7.3. La problemática de WhatsApp y aplicaciones VoIP OTT

En el ecosistema argentino, un volumen creciente de fraudes se canaliza a través de llamadas de voz de WhatsApp. Al tratarse de aplicaciones de terceros protegidas por el sandboxing estricto de Android y cifrado de extremo a extremo, ninguna app externa puede interceptar directamente el flujo de audio digital de la llamada de WhatsApp en memoria sin vulnerar el sistema operativo. La estrategia de ingeniería de VozReal para este vector contempla dos fases:

1. **Fase inicial (accesibilidad de Android y micrófono):** detección de la notificación de llamada entrante de WhatsApp mediante el servicio de accesibilidad y escucha acústica del entorno cuando el usuario activa el altavoz o el audio resuena en el micrófono superior del equipo.
2. **Fase avanzada (audios de WhatsApp diferidos):** implementación de un analizador de mensajes de voz entrantes. Cuando el usuario recibe un audio sospechoso de un familiar pidiendo auxilio económico, puede reenviarlo o compartirlo con VozReal para una verificación biométrica instantánea en 500 milisegundos antes de responder. Esta función corresponde a F8 del apartado 5.1 y es, además, la vía de entrada natural del producto para usuarios que aún no lo tienen instalado.

8. CONCLUSIONES Y HOJA DE RUTA PARA LA ETAPA SEMILLA

8.1. Síntesis de la justificación integral

El proyecto VozReal no constituye simplemente una aplicación móvil reactiva, sino un sistema sociotécnico de contramedida biométrica sólidamente sustentado en la literatura científica internacional contemporánea:

- **Sustento teórico indiscutible:** se basa en las arquitecturas más avanzadas de la biometría vocal moderna (ECAPA-TDNN) y del consorcio ASVspoof (AASIST, RawNet2), superando el análisis elemental de metadatos telefónicos.
- **Viabilidad práctica demostrable:** mediante cuantización INT8 y destilación de conocimiento, es técnicamente factible ejecutar la inferencia acústica y biométrica completa en el borde (Edge AI) en procesadores móviles de bajo costo sin violar la privacidad ni transferir datos a servidores externos.
- **Definición de producto resuelta:** el sistema queda especificado en nueve funciones núcleo, un alcance y no alcance explícito, una unidad de uso familiar con tres roles diferenciados, una base de identificación de números ya clasificados como spam o fraude y un sistema de alertas de cinco niveles con su lógica de decisión formalizada.
- **Autenticación familiar de triple factor:** VozReal no confía la decisión a una sola señal. Combina algo que el interlocutor es (la biometría de su voz), algo que tiene (el número y su reputación) y algo que sabe (la palabra clave de seguridad acordada con la familia). Este último factor es el que cierra el único escenario que ningún clasificador acústico puede garantizar por sí solo, y es además el más barato de implementar y el más fácil de explicar a la persona protegida.
- **Modelo de entrega decidido y fundamentado:** VozReal se materializa como aplicación móvil con inferencia local, diseñada para integrarse en una segunda fase como servicio de valor agregado de las operadoras. Este modelo híbrido secuencial maximiza la velocidad de llegada al mercado y la autonomía del proyecto en su etapa temprana, sin renunciar a los activos de distribución, cobro y señales de red que solo la línea telefónica puede aportar en la escala.
- **Impacto social enfocado:** diseñado específicamente para proteger el eslabón más vulnerable de la cadena digital, el adulto mayor y, por extensión, cualquier integrante vulnerable del grupo familiar, a través de heurísticas de interacción no invasivas y del empoderamiento cognitivo mediante preguntas de desafío intrafamiliar.

8.2. Hoja de ruta experimental para la etapa semilla (50 familias)

Para consolidar la transición desde la actual etapa pre-semilla hacia la etapa semilla, el equipo desarrollará las siguientes actividades experimentales en el ámbito de Santiago del Estero:

Hito metodológico	Acción concreta de validación	Métrica de éxito (KPI)
1. Recolección de corpus local	Construcción de un conjunto de datos controlado de voces regionales con entonación local (acento santiagueño) y ruido telefónico real (3G y 4G).	50 pares de voces familiares y 200 audios de prueba clonados con XTTS y ElevenLabs.
2. Calibración de umbrales	Ajuste del punto de operación sobre la curva DET para balancear la tasa de falsos positivos y falsos negativos, por cada nivel del semáforo.	EER menor al 3.5% en entorno móvil; falsos positivos en nivel rojo menores al 1%.
3. Validación del sistema de alertas	Pruebas de usabilidad con adultos mayores sobre los cinco niveles definidos en el apartado 5.8, midiendo comprensión y reacción bajo simulación de estrés.	Comprensión del mensaje superior al 90%; cero incidentes de pánico infundado; tiempo de lectura menor a 2 segundos.
4. Piloto de campo con familias	Despliegue del prototipo APK en los teléfonos de 50 adultos mayores con la colaboración de sus hijos o nietos, incluyendo el flujo de enrolamiento remoto.	Al menos 80% de círculos familiares con tres o más voces enroladas; retención a 60 días superior al 70%.
5. Validación del protocolo de palabras clave	Acompañamiento a las 50 familias en la definición, el acuerdo presencial y la rotación de la palabra de identificación y de la palabra de coacción, midiendo adopción y retención mnémica.	Al menos 70% de familias con palabra clave acordada y recordada correctamente a los 60 días; cero filtraciones reportadas.

Hito metodológico	Acción concreta de validación	Métrica de éxito (KPI)
6. Vinculación con fuerzas especializadas	Intercambio técnico de tipologías de engaño con la División de Ciberdelitos de la Policía de la Provincia y juzgados intervinientes.	Validación institucional de los patrones de llamada detectados.
7. Exploración de la alianza con operadoras	Presentación del modelo de servicio de valor agregado y de la Capa 0 ante las áreas de innovación y de producto de al menos dos operadoras nacionales.	Una carta de intención o acuerdo de prueba de concepto firmada antes del cierre de la etapa semilla.

9. REFERENCIAS BIBLIOGRÁFICAS Y CIENTÍFICAS

[1] Desplanques, B., Thienpondt, J., y Demuynck, K. (2020). ECAPA-TDNN: Emphasized Channel Attention, Propagation and Aggregation in TDNN Based Speaker Verification. En Proc. Interspeech 2020, pp. 3830-3834. DOI: 10.21437/Interspeech.2020-2650.

[2] Tak, H., Patino, J., Todisco, M., Nautsch, A., Evans, N., y Larcher, A. (2021). End-to-End Spectro-Temporal Graph Attention Networks for Speaker Verification Anti-Spoofing and Countermeasures. En Proc. IEEE Automatic Speech Recognition and Understanding Workshop (ASRU), pp. 1114-1121.

[3] Jung, J. W., Heo, H. S., Tak, H., Shim, H. J., y Chung, J. S. (2022). AASIST: Audio Anti-Spoofing Using Integrated Spectro-Temporal Graph Attention Networks. En Proc. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), pp. 6367-6371.

[4] Delgado, H., Todisco, M., Sahidullah, M., Evans, N., Kinnunen, T., Lee, K. A., y Yamagishi, J. (2021). ASVspoof 2021: Towards Spoofed and Deepfake Speech Detection in the Wild. IEEE/ACM Transactions on Audio, Speech, and Language Processing.

[5] Müller, N. M., Dieckmann, F., y Böttinger, K. (2022). In-the-Wild Audio Deepfake Dataset. arXiv preprint arXiv:2210.02870.

[6] Snyder, D., Garcia-Romero, D., Sell, G., Povey, D., y Khudanpur, S. (2018). X-Vectors: Robust DNN Embeddings for Speaker Recognition. En Proc. IEEE ICASSP 2018, pp. 5329-5333.

[7] Spreng, R. N., Karlawish, J., y Marson, D. C. (2016). Cognitive, Social, and Neural Determinants of Diminished Decision-Making and Financial Exploitation Risk in Aging and Dementia: A Review and Theoretical Model. The Journal of Gerontology: Series B, 71(4), 670-681.

[8] Castle, E., Eisenberger, N. I., Seeman, T. E., Moons, W. G., Boggero, I. A., Grinblatt, M. S., y Taylor, S. E. (2012). Neural foundation of age-related declines in the physiological detection of trustworthiness. Proceedings of the National Academy of Sciences (PNAS), 109(51), 20848-20852.

[9] Unidad Fiscal Especializada en Ciberdelincuencia, UFECI (2024). Informe de Gestión y Estadísticas sobre Ciberdelitos en la República Argentina. Ministerio Público Fiscal de la Nación.

[10] Congreso de la Nación Argentina (2000). Ley Nacional N° 25.326 de Protección de los Datos Personales. Boletín Oficial de la República Argentina.

[11] Ente Nacional de Comunicaciones, ENACOM (2014). Ley N° 27.078: Argentina Digital, Marco Regulatorio de las Tecnologías de la Información y las Comunicaciones. República Argentina.

[12] ATIS / SIP Forum (2020). Signature-based Handling of Asserted information using toKENs (SHAKEN). ATIS Standard 1000074.

[13] Nielsen Norman Group (2024). Usability for Senior Citizens: Improving the User Experience for Older Adults. NN/g Research Report.

[14] W3C (2023). Web Content Accessibility Guidelines (WCAG) 2.2. World Wide Web Consortium Recommendation.

[15] GSMA (2024). Mobile Value Added Services and Fraud Prevention in Emerging Markets. GSMA Intelligence Report.